

Conceptos fundamentales del análisis de datos

2do. cuatrimestre 2026


Dato

Es la representación de un hecho, una observación o una característica de un objeto, persona o evento, expresada mediante números, texto, fecha, símbolos o cualquier otro formato.

Por sí solo, un dato carece de contexto y significado suficiente para tomar decisiones.

Ejemplos: 38.5, “Azul”, 2026-08-04, 125, “Juan Pérez”

Tipos de datos según su estructura



¿De qué trata el análisis de datos?



Definición de wikipedia

“El análisis de datos es un proceso que consiste en inspeccionar, limpiar y transformar datos con el objetivo de resaltar información útil, para sugerir conclusiones y apoyo en la toma de decisiones.”

[Link](#)

Perspectiva académica del análisis de datos

Una visión más vinculada a la academia y al campo de la estadística, tiende a reducir el análisis de datos a la estadística descriptiva o inferencial.


La **estadística descriptiva** es aquella que se aboca al análisis de los datos disponibles. La **estadística inferencial** busca, a partir de una muestra de un universo dado, generar predicciones o definiciones generales para ese universo.

El análisis de datos en la actualidad

Sin embargo, el analista de datos suele utilizar técnicas que exceden al campo tradicional de la estadística descriptiva o inferencial. Y se suele recurrir también al aprendizaje automático y la minería de datos.

“El análisis descriptivo es el paso inicial generalmente recomendado para comprender la estructura de los datos disponibles y la extracción de la información relevante para el análisis.” (Chan, Badano y Rey)

A partir del crecimiento exponencial de la cantidad de datos disponibles en la web surgen gigantescas bases de datos.



Data Mining y Big Data

“La minería de datos, data mining en inglés, surge con el análisis de los datos sociales de Quetelet, los datos biológicos de Galton y los datos agronómicos de Fisher.” [Siglo XIX] (Chan, Badano y Rey; página 5)

“forma parte de un proceso conocido como ‘descubrimiento de conocimiento a partir de los datos’ (KDD: Knowledge Discovery in Databases). El objetivo es extraer información de una gran base de datos, sin disponer de conocimiento previo para construir patrones y/o relaciones sistemáticas de valor, así como anomalías.”

(Chan, Badano y Rey; página 7)

La **Big data** se puede resumir en las tres “V”. Esto es información en grandes **volúmenes**, que requiere alta **velocidad** de procesamiento, y que se encuentran en **variedad** de formas. Se suelen tener en cuenta otras dos “V”s más: **veracidad** y **valor**.

Análisis estadístico Vs. Minería de datos

1. Procedimiento hipotético deductivo
2. Técnicas confirmatorias
3. Supuestos iniciales
4. Herramientas informáticas opcionales

1. Procedimiento inductivo
2. Técnicas exploratorias
3. Sin supuestos iniciales
4. Recursos informáticos indispensables

El análisis se puede realizar sobre distintos tipos de variables

- ❑ **Categóricas:** no se pueden ordenar, son cualitativas.
- ❑ **Ordinales:** se pueden ordenar, pero no establecer distancia.
- ❑ **Cuantitativas discretas:** son variables numéricas que entre dos valores consecutivos no poseen valores intermedios.
- ❑ **Cuantitativas continuas:** son numéricas que entre dos valores poseen infinitos valores intermedios

Clasificación del análisis según la cantidad de variables a tener en cuenta

Univariado

Como la palabra lo indica trata sobre el análisis de una sola variable a la vez.

Se pueden obtener **medidas de tendencia central** como la media, la mediana y la moda o de **dispersión** como varianza y rango u **otras** como curtosis.

Ejemplo: media etaria del aula.

Bivariado o multivariado

Se aplica cuando se busca analizar dos o más variables. Tanto a nivel de su relación, dependencia o patrones.

Un ejemplo puede ser una clusterización de los clientes de una empresa, una regresión entre edad y peso, etc.

Tecnologías útiles al análisis de datos

Tecnologías utilizadas





Conceptos estadísticos fundamentales

Ley de los grandes números

Este concepto, formulado originalmente por Jacob Bernoulli en el siglo XVII, establece que la frecuencia relativa de un evento tiende a converger hacia su probabilidad teórica a medida que aumenta el número de ensayos.

En el contexto de la estadística inferencial, esto implica que, a medida que crece el tamaño de una muestra tomada de una población, la media muestral tiende a aproximarse cada vez más al valor esperado (esperanza matemática) de la población.

Teorema central del límite

Fue desarrollado originalmente entre los siglos *XVIII* y *XIX*. Pero hasta el *S XX* se continuó reformulando.

El Teorema Central del Límite establece que, dada una población con cualquier distribución, la distribución de las medias muestrales tiende a una distribución normal a medida que el tamaño de la muestra aumenta, siempre que la varianza poblacional sea finita.

