

Data cleaning

El paso previo al análisis de datos

Link del colab de la clase

Etapas del análisis de datos

- 1- Recolección de los datos.
- 2- Almacenamiento.
- 3- Limpieza y preprocesamiento de datos.
- 4- Análisis.
- 5- Visualización y/o modelado.

¿Por qué es necesaria la limpieza de los datos?

Una vez que contamos con un conjunto de datos correctamente almacenados para su posterior análisis, debemos realizar un paso previo al análisis de datos, la limpieza de los mismos.

Existen diversos inconvenientes que pueden aparecer a la hora de analizar los datos y es preciso resolver: valores nulos, duplicados o elementos atípicos son los problemas más comunes.

Valores duplicados

Los datos duplicados son problemáticos ya que generan la sobrerrepresentación de aquellos registros afectados y pueden conducir a estimaciones erradas.

En la mayoría de los casos, su solución es relativamente sencilla y se resuelve eliminando los elementos repetidos.

Utilizando pandas:

```
df.drop_duplicates()
```

Valores perdidos o no respuesta

Los valores perdidos pueden o no ser un problema dependiendo de las características que tome la no respuesta. Si ella es absolutamente aleatoria no será difícil resolverla, en caso contrario los valores perdidos se pueden transformar en un gran dolor de cabeza para el analista de datos y su solución puede ser un ejercicio de ciencia de datos en sí mismo.

Patrones de la no respuesta

Puede ser soslayada

Completamente aleatoria: se dan cuando no existe ningún patrón, ni asociación con otras variables del conjunto de datos. En este caso no introducen ningún tipo de sesgo a las estimaciones.

No puede ser soslayada

Aleatoria: hay una dosis de azar en la no respuesta, así como se encuentra condicionada por otras variables del dataset.

No aleatoria: la no respuesta a una variable se explica completamente por por sí misma.

Posibles soluciones

Completamente aleatoria:

Eliminación de los registros con no respuesta.

df = df.dropna()

Aleatoria o no aleatoria

Dependiendo de la tasa de no respuesta de la variable y las características de la misma, se pueden evaluar distintas soluciones:

imputación de medias, imputación de valores definidos arbitrariamente, elaboración de modelos para imputación probabilística, ponderación y/o reponderación, etc.

Conclusión sobre cómo solucionar valores perdidos

Es una decisión metodológica del investigador/analista. Su solución puede ser sencilla o compleja, según los objetivos del análisis y las características de la no respuesta. No hay una respuesta automática.

Tratamiento de valores atípicos (outliers) o inconsistentes

¿Qué es un valor atípico?


“Los datos recolectados poseen con frecuencia una o más observaciones atípicas; es decir datos alejados de alguna forma del patrón general del conjunto.”

¿Qué es un valor inconsistente?

Es un dato que no posee coherencia con respecto al conjunto de observaciones o a los conocimientos previos sobre el tema en estudio.

Ejemplos de valores inconsistentes

- En una encuesta a personas, una persona que responde que tiene 250 años.
- En una variable de coordenadas un punto que se encuentra fuera del territorio en análisis.
- Un valor de tipo distinto al del conjunto.



Ejemplos de valores atípicos

- Una persona que declara que tiene 105 años.
- En una variable de coordenadas un punto que se encuentra aislado y alejado del resto, pero dentro del territorio en análisis.
- Si estudiamos salarios, el salario del jugador mejor pago del fútbol argentino.

Cómo tratar valores atípicos o inconsistentes

Los valores atípicos no necesariamente deben ser excluidos del análisis, ni modificados.

Pueden ser identificados intuitivamente, así como con técnicas estadísticas o de aprendizaje automático. Deben ser cuidadosamente inspeccionados y su inclusión en el análisis dependerá de los objetivos del mismo.

Los valores inconsistentes deben corregirse o eliminarse. Bajo ningún punto de vista pueden ser tenidos en cuenta en el análisis.