

Estadística aplicada al análisis de datos

[Colab de la clase](#)

Organización de los datos

“Una vez definida la base de datos con toda la información disponible, es necesario ordenarla y organizarla, a fin de facilitar su comprensión e interpretación. El análisis sobre los datos crudos, puede resultar inabordable.”

Chan, Badano y Rey

Análisis de frecuencias

En datos **cualitativos**, se realiza un conteo de la cantidad de veces que se repite cada categoría.

La frecuencia puede ser absoluta o porcentual.

En datos **cuantitativos** podemos analizar frecuencias de distintas maneras. En el caso de que la variable no sea discreta, será necesario utilizar intervalos.

La frecuencia puede ser absoluta o porcentual.

Medidas descriptivas univariadas

Medidas de tendencia central

“Las medidas de tendencia central son resúmenes estadísticos que pretenden representar a un conjunto de valores con un solo valor.”

Utilizando Pandas se pueden calcular medidas de tendencia central como la media, mediana y moda. Por otro lado utilizando otras librerías como *scipy* se pueden estimar algunas medidas más sofisticadas como la media geométrica o la media podada.

Medidas de posición

Son medidas que permiten dividir al conjunto de datos en partes iguales.

Utilizando Pandas podemos obtener estas medidas como la mediana, cuartiles, deciles, percentiles, etc.

Medidas de dispersión

“Las medidas de dispersión indican la variabilidad de los datos. La mayoría cuantifica el grado de concentración de los datos alrededor de una medida de posición.”

Análisis bivariado

¿Qué es el análisis bivariado?

Implica el análisis de dos variables de forma conjunta. El caso más común es una variable independiente y una dependiente. Algunos ejemplos pueden ser:

- Peso según altura.
- Desocupación según aglomerado.
- Ingreso según ocupación.

También puede haber análisis de tipo simétricos que no impliquen causalidad.

Covarianza

Mide la variabilidad conjunta de dos variables. Es una medida de asociación lineal. Al no estar estandarizada, depende de la escala de las variables.

$$cov_{x,y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{N - 1}$$

Correlación

En su versión original (Pearson), es una medida de asociación lineal entre dos variables que estandariza la covarianza produciendo valores entre 1 y -1. Lo cual la hace más comparable.

Existe una versión alternativa desarrollada por Spearman trabaja con rangos en lugar de valores numéricos. Lo cual la hace menos sensible a valores extremos.

En variables categóricas se puede utilizar V de Cramer.

En variables numéricas y categóricas la prueba t de Student o el coeficiente eta.

Análisis multivariado

Cómo se presenta la información multivariada

Registros: son los elementos sobre los cuales se miden los atributos y se encuentran en las filas.

Variables: son los atributos que interesa estudiar. Se encuentran en las columnas.

Usualmente se define a las variables o columnas con la letra p y a las filas con la n .

Complejidad del análisis multivariado

El análisis multivariado comprende el estudio de cada variable aisladamente y de las relaciones que se establecen entre aquellas que nos interese analizar. A medida que aumenta la cantidad de variables a tener en cuenta, el análisis se vuelve más complejo. La cantidad de parámetros a tener en cuenta se calcula con la siguiente fórmula:

$$2p + (p \cdot (p-1)) / 2$$

Técnicas más avanzadas

Algunos ejemplos

- Análisis de componentes principales
- Análisis de correspondencias
- Clusterización
- Modelado