

🔗 Introducción al Análisis de Datos — Guía de estudio unificada (clases + libro)

UTN Avellaneda · Tecnicatura Universitaria en Programación · 2do. cuatrimestre 2026

Docente: Fernández, Luis N.

Libro base: *Análisis inteligente de datos con lenguaje R* — Débora Chan, Cristina Inés Badano, Andrea Alejandra Rey (edUTecNe, UTN, 1ª ed., 2019). Temática: minería de datos, componentes principales, contrastes de independencia, análisis de correspondencias, escalamiento multidimensional y métodos de clasificación supervisada y no supervisada.

🔗 Índice

Hacé clic en cualquier tema para ir directo. Cada sección tiene un enlace 🔗 **Volver al índice** al inicio.

- 🔗 **PANEL DEL PARCIAL (leer primero)**
 - Logística (dicha en clase)
 - ¿Qué temas entran?
 - Preguntas que mencionó explícitamente (las más probables)
 - Lo que dijo que NO va a tomar
- 1. 🔗 **Conceptos fundamentales del análisis de datos (Clase 1 + Cap. 1)**
 - 1.1 Dato
 - 1.2 Tipos de datos según su estructura
 - 1.3 ¿De qué trata el análisis de datos? (el proceso)
 - 1.4 Definiciones de análisis de datos
 - 1.5 Contexto histórico, Data Mining y Big Data
 - 1.6 Análisis estadístico vs. Minería de datos 🔗 (cuadro clave)
 - 1.7 Tipos de variables 🔗
 - 1.8 Clasificación según cantidad de variables
 - 1.9 Tecnologías (la "pata tecnológica")
- 2. 🔗 **Conceptos estadísticos fundamentales**
 - 2.1 Ley de los grandes números (LGN) 🔗
 - 2.2 Teorema central del límite (TCL) 🔗
- 3. 🔗 **NumPy — manipulación eficiente de vectores**
 - 3.1 ¿Qué es?
 - 3.2 La clase `numpy.ndarray` 🔗
 - 3.3 Atributos y métodos
 - 3.4 Experimento de la clase 🔗 (lista vs. NumPy)
 - 3.5 Imágenes como arrays 🔗
- 4. 🔗 **Pandas — análisis de datos estructurados**
 - 4.1 ¿Qué es?
 - 4.2 Estructuras básicas
 - 4.3 Selección de columnas
 - 4.4 Filtrado de filas
 - 4.5 Índices: `loc` vs `iloc`

- 4.6 Fechas y texto
- 4.7 Datos usados en clase [?](#)
- **5. [?](#) Data cleaning — limpieza y preparación**
 - 5.1 Contexto (ETL) y etapas [?](#)
 - 5.2 Valores duplicados
 - 5.3 Valores perdidos o "no respuesta" (datos faltantes)
 - 5.4 Valores atípicos (outliers) e inconsistentes [?](#)
- **6. [?](#) Transformación de datos**
 - 6.1 Transformaciones por variables (columnas)
 - 6.2 Transformaciones por individuo (filas)
- **7. [?](#) Análisis estadístico de datos**
 - 7.1 Organización de los datos
 - 7.2 Análisis de frecuencias
 - 7.3 Medidas descriptivas univariadas (una variable a la vez)
 - 7.4 Análisis bivariado
 - 7.5 Análisis multivariado
 - 7.6 [?](#) Ejercitación del libro (Cap. 2)
- **8. [?](#) Resumen rápido (tablas para repasar)**
 - 8.1 Qué hacer con cada problema de datos
 - 8.2 NumPy vs. Pandas
 - 8.3 Medidas: de qué "familia" son
 - 8.4 Transformaciones
 - 8.5 Patrones de no respuesta (semáforo)
 - 8.6 Σ vs. R
- **9. [?](#) Mnemotecnias**
- **10. [?](#) Preguntas de autoevaluación**
- **11. [?](#) Información de cursada**
 - Aprobación y asistencia [?](#)
 - Bibliografía [?](#)
 - TP final [?](#)
- **12. [?](#) Anexo: Álgebra lineal y Análisis de Componentes Principales (Cap. 3 del libro)**
 - 12.1 Nociones previas de álgebra lineal
 - 12.2 Transformaciones lineales
- **13. Glosario**

⚡ Accesos rápidos (lo que más probablemente entra)

- Estadística vs. minería (cuadro clave)
- Big Data: las 3 V (+2)
- Tipos de variables
- NumPy y `ndarray`
- Atípico vs. inconsistente
- Z-score y transformaciones
- La mediana: ¿central o posición?
- Interpretar una matriz de correlación
- LGN vs. TCL
- Preguntas de autoevaluación

Referencias

Ícono	Significado
	El docente dijo que entra / puede entrar / es pregunta de parcial
	Información agregada desde las clases (no está en las diapositivas)
	Información del libro (Chan, Badano y Rey) que complementa o amplía las clases
	Aclaración para evitar confusiones
	Truco para memorizar
	Lo que el docente dijo que NO entra (se conserva por completitud)

📄 PANEL DEL PARCIAL (leer primero)

[📄 Volver al índice](#)

Logística (dicha en clase)

Dato	Detalle
Fecha	Viernes 2 de octubre
Lugar	Aula 308, presencial
Formato	Escrito, a mano (hoja y lapicera). Preguntas teóricas a desarrollar + múltiple choice
Contenido	100 % teórico : no hay cálculos ni hay que programar
Traer	DNI, lapicera, dos hojas
Prohibido	Celulares y cualquier IA (ChatGPT, Gemini, etc.). "Que hayan estudiado y comprendan con sus palabras"
Modelo de parcial	No hay . Se estudia lo visto
Horario	Arranca ~10–20 min después de la hora (el docente sabe que muchos vienen del trabajo)
Duración	En general se responde rápido (mencionó ~media hora; la frase no se entiende bien en la transcripción)
Mismo día	Se rinde el mismo día que Legislación
Recuperatorio	16 de octubre
Constancia de examen	El docente la firma después del parcial (se pide en el Departamento de Alumnos / administración); también da el certificado de alumno regular
Aviso	Iba a mandar un mensaje por el campus con los detalles

¿Qué temas entran?

- **Todo hasta la clase del 25/09 inclusive** → los **5 temas**: Clase 1 (conceptos), NumPy/Pandas, Data cleaning, Transformación de datos y Análisis estadístico (univariado, bivariado, multivariado).
- **Fuentes que pueden entrar**: los **dos primeros capítulos** de *Chan, Badano y Rey* (~70–73 págs.), los **ejercicios**, los **colabs** y los **apuntes/presentaciones**.
- 📄 **NO entra**: visualización / gráficos (Unidad 4), análisis de componentes principales y de correspondencias (están en el libro pero "no entran en la materia").

Preguntas que mencionó explícitamente (las más probables)

#	Pregunta / tema	Dónde lo dijo	Dónde está en esta guía
1	📄 Relación / diferencias entre análisis de datos y minería de datos (a desarrollar, "seguro")	25/09 y 11/09	§1.6
2	📄 Ciencia de datos vs. análisis de datos : qué es cada una, diferencias, características	11/09	§1.4–1.6
3	📄 Cuadro de doble entrada estadística vs. minería de datos	25/09	§1.6

#	Pregunta / tema	Dónde lo dijo	Dónde está en esta guía
4	🔗 Big Data: las 3 V (+2) — "tema de parcial de acá a la China"	Clase 1	§1.5
5	🔗 Tipos de variables — "pregunta recontra de parcial... si la contestan mal, van directo al dos"	25/09	§1.7
6	🔗 ¿Por qué es tan importante NumPy? / características e importancia de ndarray	04/09	§3
7	🔗 Diferencia entre valor inconsistente y valor atípico ("pregunta muy común de parcial")	11/09	§5.4
8	🔗 ¿Qué es el Z-score y para qué sirve? (cuántos desvíos estándar se aleja un registro de la media; detecta atípicos)	11/09 y 25/09	§5.4 y §6
9	🔗 ¿Qué tipo de medida es la mediana? → <i>pregunta trampa: tendencia central Y posición</i>	25/09	§7.3
10	🔗 Interpretar una matriz de correlación ("a lo sumo les voy a pedir eso")	25/09	§7.4
11	🔗 Interpretar un boxplot — lo dijo el 11/09, pero el 25/09 aclaró que gráficos no entran → repasarlo por las dudas	11/09	§5.4 y §7.3
12	Ley de los grandes números vs. Teorema central del límite (se confunden) + vínculo TCL ↔ test de hipótesis (tarea)	Clase 1	§2

Lo que dijo que NO va a tomar

- Código / programar / cálculos / "qué hace tal función de NumPy".
- ✗ "Qué es un dato" y la definición de Wikipedia (*no es pregunta de parcial*). 🔗 Igual conviene manejar la idea: el dato aislado no sirve, hay que contextualizarlo.
- R, Cassandra/NoSQL (herramientas/curiosidades, no para tomar).

1. ? Conceptos fundamentales del análisis de datos (Clase 1 + Cap. 1)

[? Volver al índice](#)

1.1 Dato

- Representación de un **hecho**, **observación** o **característica** de un objeto, persona o evento (números, texto, fecha, símbolos...).
- Por sí solo **carece de contexto y significado** para tomar decisiones. Ejemplos: **38.5**, **"Azul"**, **2026-08-04**, **125**, **"Juan Pérez"**.
- ? **"El dato no habla por sí solo, hay que contextualizarlo."** El análisis de datos consiste en **darle contexto y contar una historia** a partir de los datos; para eso hay que cumplir **una serie de pasos**.
- ? **"En el análisis de datos hay grises, no hay blanco y negro."** No hay respuestas mágicas; depende del contexto y del significado que se le dé.
- ? Los datos **no se estudian de forma aislada**: se trabaja con datos organizados de alguna manera.

1.2 Tipos de datos según su estructura

Tipo	Qué es	Ejemplos
Estructurados	Tablas : filas y columnas. Columnas = variables , filas = registros	Tabla ID/Nombre/Edad/Ciudad, bases de datos relacionales
Semiestructurados	Cierta organización sin tabla rígida	JSON, XML, CSV , respuestas de APIs , logs
No estructurados	Sin formato de tabla	Texto, imágenes, video, audio, PDF, emails, redes sociales

- ? Los **LLM** trabajan con datos **no estructurados** (el lenguaje lo es); lo mismo la IA de sonido, imagen y video.
- ? **Este cuatrimestre se trabaja principalmente con datos estructurados**; la IA está muy ligada a los no estructurados.

1.3 ¿De qué trata el análisis de datos? (el proceso)

Recolección → Limpieza → Transformación → Exploración y visualización → Interpretación → Conocimiento accionable

- **Recolección**: bases de datos, archivos, encuestas.
- **Conocimiento accionable**: toma de decisiones, resolución de problemas, respuestas a preguntas.
- ? **Quién recolecta**: en general **no es el analista** (los datos vienen de sensores, páginas web, encuestadores, bases existentes). **Excepción: web scraping** (ej.: extraer precio, kilómetros y modelo de una web de venta de autos).
- ? **Las etapas no son estrictamente secuenciales**: hay **ida y vuelta** (ej.: en la visualización se puede descubrir que la limpieza estuvo mal y volver atrás).
- ? Los datos **no tienen valor en sí mismos**: lo tienen por el **trabajo que se hace sobre ellos**.
- ? **Preparación de los datos (libro)**: trabajar con bases masivas exige planificación. Hay que considerar: (1) los **objetivos reales** del análisis; (2) **recursos tecnológicos y de tiempo** disponibles; (3) **organización y estructuración** de los datos en bruto; (4) **costos** del estudio; (5) **interpretación y redacción de informes** accesibles para la toma de decisiones.

1.4 Definiciones de análisis de datos

- **Wikipedia:** proceso de **inspeccionar, limpiar y transformar** datos para **resaltar información útil, sugerir conclusiones** y **apoyar la toma de decisiones**.
- **?** **No hay una sola forma de analizar datos;** fue cambiando mucho a lo largo de la historia.

Perspectiva académica / tradicional (estadística clásica; texto de Hernández, U. de La Rioja): reduce el análisis a estadística **descriptiva** o **inferencial**.

- **Descriptiva:** analiza **los datos disponibles** (asume que son todos). **?** Ej.: media, máximo y mínimo de una variable.
- **Inferencial:** a partir de una **muestra** (recorte del universo) genera **predicciones/generalizaciones para el universo**. **?** Ej.: encuestas de imagen de candidatos: se entrevistan 1.000–3.000 casos para inferir lo que piensa toda la población votante.

En la actualidad:

- Se usan técnicas que **exceden** la estadística tradicional: **aprendizaje automático** y **minería de datos**; **?** por ejemplo **árboles de decisión, ensambles, redes neuronales** ("no es un capricho: funcionan").
- Cita (Chan, Badano y Rey): el **análisis descriptivo sigue siendo el paso inicial** recomendado para comprender la estructura de los datos.
- **?** La estadística tradicional era "cuadrada y rígida"; se flexibilizó y **aparecieron la ciencia de datos, la IA y el machine learning** (campo más ligado a la informática).

1.5 Contexto histórico, Data Mining y Big Data

Origen de la estadística **?**: surge hacia el **3.er milenio a. C.** en el **Estado egipcio**; el nombre viene de "**dar cuenta de la situación del Estado**" (censos: situación económica, social, laboral). Disciplina de ~5.000 años; la minería de datos (siglo XIX) es "casi nueva".

Por qué cambió el panorama (desde los **años 90**):

- Desarrollo tecnológico: procesadores cada vez más potentes.
- **Explosión de datos** de aplicaciones web (gráfico w3resource): **Business Transaction Data** crece casi linealmente; **Web Application Data** crece **exponencialmente**.
- **?** Volúmenes masivos actuales: transacciones, redes móviles, sensores, internet. La estadística tradicional resulta **limitada** ante su tamaño y complejidad → paradigma del *Data Mining*. (En la posguerra la estadística clásica vivió su "edad de oro".)
- Procesar esos datos genera **ganancias** o **conclusiones científicas útiles** → hacen falta **nuevas herramientas y tecnologías**.

Orígenes de la minería de datos **?**

Raíces en el análisis de datos de grandes pensadores que aplicaron la estadística clásica (siglo XIX):

- **Adolphe Quetelet (física social):** demostró que fenómenos sociales (como el delito) tienen **regularidad estadística** y están influenciados por factores medibles (pobreza, clima). (*Datos sociales.*)
- **Francis Galton (ciencias humanas):** introdujo la **correlación**, la **regresión** y el uso de **encuestas/cuestionarios** para estudiar comunidades humanas y la herencia. (*Datos biológicos.*)
- **Ronald Fisher (agronomía y genética):** desarrolló el **análisis de la varianza** aplicado a cultivos y formuló principios de la genética de poblaciones. (*Datos agronómicos.*)

Data Mining (minería de datos)

- Forma parte del proceso **KDD** (*Knowledge Discovery in Databases*, "descubrimiento de conocimiento en bases de datos"). El *Data Mining* es su **fase analítica**.

- **Meta:** extraer información útil, **patrones y/o relaciones sistemáticas de valor y anomalías** de una gran base de datos **sin conocimiento previo** de lo que se busca. ? No solo importa *qué* pasa sino **por qué** pasa.
- ? **Naturaleza multidisciplinaria:** integra **bases de datos, aprendizaje automático (Machine Learning), inteligencia artificial, estadística, computación y procesamiento de imágenes**.
- ? **"Sin conocimiento previo" = aproximación empírica y exploratoria:** se llega a los datos "con la cabeza vacía", sin marco teórico ni hipótesis; **no** se dice "mi hipótesis es esta, veamos si se valida".
- ? **Metáfora de la minería:** el minero excava una montaña y **separa lo útil/valioso de lo que no lo es** → la **limpieza** es parte obvia del proceso.
- ? **Dominios de aplicación:** procesamiento de imágenes y señales, minería web, detección de fraudes, bioinformática.

Big Data ?

V	Significado
Volumen	Grandes cantidades de información
Velocidad	Requiere alta velocidad de procesamiento
Variedad	Información en muchas formas
Veracidad	(adicional) confiabilidad
Valor	(adicional) utilidad

- ? **¿Por qué Big Data no se define con un número** (ej. >100.000 TB)? Porque la capacidad de procesamiento **crece constantemente** y cualquier cifra queda chica (hace 50 años una computadora ocupaba una habitación; hoy un celular procesa mucho más; se discute la computación cuántica). Por eso se pasó a un **concepto**.
- ? Los conceptos "de moda" cambian: ciencia de datos → minería de datos → big data → **inteligencia artificial**; están muy relacionados y la disciplina está en **evolución permanente**.

Terminología de conectividad ?

El análisis de datos moderno se alimenta del hiper-conectivismo actual:

- **M2M (Machine to Machine):** comunicación directa entre máquinas remotas **sin intervención humana** (sensores meteorológicos, alarmas, terminales de venta, gestión de flotas). Permite control en tiempo real y reducción de costos.
- **IoT (Internet of Things):** interconexión digital de objetos cotidianos (heladeras, *wearables* como relojes inteligentes) mediante sensores e internet. Término acuñado por **Kevin Ashton en 1999 (MIT)**.
- **WoT (Web of Things):** capa de aplicación que integra los objetos físicos e inteligentes de IoT a la arquitectura y patrones de la **World Wide Web**.
- **IoE (Internet of Everything):** filosofía más amplia (impulsada por empresas como Cisco) que conecta inteligentemente **personas, procesos, datos y cosas**; promete reinventar modelos de negocio a escala global.

1.6 Análisis estadístico vs. Minería de datos ? (cuadro clave)

#	Análisis estadístico (clásica)	Minería de datos
1	Procedimiento hipotético-deductivo	Procedimiento inductivo
2	Técnicas confirmatorias	Técnicas exploratorias
3	Con supuestos iniciales	Sin supuestos iniciales

#	Análisis estadístico (clásica)	Minería de datos
4	Herramientas informáticas opcionales / de apoyo	Recursos informáticos indispensables / uso intensivo

Explicación dada en clase 📖:

- **Hipotético-deductivo:** se plantea una hipótesis y se **contrasta con la realidad**. **Inductivo:** se **generaliza** a partir de los datos, **sin hipótesis ni conocimiento previo**; "llegamos a los datos y vemos qué pasa".
 - Epistemología: hasta hace unos años el hipotético-deductivo estaba "bien visto" y el inductivo "mal visto"; con enormes volúmenes de datos **se volvió a necesitar el inductivo**.
 - Lo inductivo "hay que agarrarlo con pinzas": toda generalización puede terminar **falseándose**.
- **Confirmatorias vs. exploratorias:** la estadística busca **aceptar o rechazar** una hipótesis; la minería **no quiere aceptar ni rechazar nada, explora**. Obliga a **convivir con el error** (imágenes de IA que fallan, **alucinaciones**); el error **se reduce pero nunca se elimina**.
- **Supuestos iniciales** = *supuestos estadísticos* (no hipótesis): condiciones matemáticas que deben cumplirse (ej.: la variable debe ser **normal** para aplicar cierta regresión). Los modelos de ML/IA intentan **no requerirlos**. Con datos estructurados la estadística tradicional y el ML funcionan; **la gran diferencia de la minería está en los datos no estructurados**.
- **Informática:** en el siglo XIX la minería surgió sin recursos informáticos; hoy son **indispensables** por el **gran volumen de datos**.
- 📖 **IA actual e inducción:** los modelos actuales **generalizan** (inductivo) y **no aplican el método hipotético-deductivo**, aunque "traten de dibujarlo". La **IA general (AGI)** sería capaz de razonar como un humano con ese método.

📖 **Estadística = DEductivo, CONfirmatorio, CON supuestos, informática opcional. Minería = INductivo, EXploratorio, SIN supuestos, informática indispensable.**

1.7 Tipos de variables 📖

Tipo	Característica	Ejemplos
Categóricas (cualitativas)	No se pueden ordenar; modalidades sin orden jerárquico	Nombre, ciudad, color, sexo ("no puedo decir que Buenos Aires es más que Córdoba")
Ordinales (cuasicuantitativas)	Sí se ordenan, no se establece distancia exacta entre modalidades	Atención: muy buena / buena / regular / mala; calificaciones; estadios de una enfermedad
Cuantitativas discretas	Numéricas; entre dos valores consecutivos no hay intermedios (conteo)	Cantidad de hijos (no existe 1,5 hijos)
Cuantitativas continuas	Numéricas; entre dos valores hay infinitos intermedios (medición)	Distancias, peso, tiempo

- 📖 **Escala subjetiva:** medición analógica o visual aplicada a percepciones (grado de dolor o de satisfacción).
- 📖 Según el tipo **cambian los conteos, medidas y estimaciones aplicables** (como el operador + que concatena strings pero suma enteros).
- 📖 **Error grave en el TP final:** aplicar técnicas de variables cuantitativas a categóricas → **"motivo de ir a recuperatorio"**.

1.8 Clasificación según cantidad de variables

Tipo	Descripción	Ejemplos
Univariado	Una variable a la vez. Tendencia central (media, mediana, moda), dispersión (varianza, rango), otras (curtosis)	Media de edad del aula
Bivariado	Dos variables: relación, dependencia	Correlación, covarianza, regresión edad–peso
Multivariado	Más de dos variables	Clusterización de clientes, regresión múltiple

1.9 Tecnologías (la "pata tecnológica")

El análisis de datos tiene **una pata tecnológica y una pata estadística**.

- **SQL**: permite la **persistencia** de los datos; diseñado con criterio de **persistencia y consistencia** (ej.: cuenta bancaria).
- **Bases NoSQL**: otros criterios. En **redes sociales** importa la **velocidad**, no toda la información. Algunas subsisten aunque se pierda un nodo/data center; una base que priorice consistencia "se cae hasta que vuelva el nodo".
- **Bases columnares (ej.: Cassandra)** ☒: SQL organiza por **filas**; las **columnares trabajan columna por columna**, criterio más útil para análisis de datos.
- **R**: lenguaje **especializado en análisis de datos** (enfoque estadístico); el libro usa ejemplos en R.
- **Python** ☒: fundado por **Guido van Rossum en 1989**. Filosofía: **legible y accesible** ("un programador pasa más tiempo leyendo que escribiendo código"). **Multiparadigma** (OO, funcional).
 - En los 90 era criticado (predominaban lenguajes muy optimizados). En 2000 ni aparecía en el ranking; ~2015 era 3.º (R 10.º); C cae. Alrededor de **2017** aparece el paper "**Attention Is All You Need**" → explota la IA y Python sube; hoy es **el lenguaje más usado** y **el de la IA y las redes neuronales**. R queda desplazado.
 - **NumPy** fue "la razón por la que Python es lo que es".
- ☒ **Otras herramientas (libro): WEKA** (colección de algoritmos en Java), SAS Enterprise Miner, Statistica Data Miner, SPSS Clementine (IBM), IBM Intelligent Miner, SPAD, SODAS. *Contexto actual*: computación en la nube (AWS, Google Cloud, Azure) y ecosistemas de Big Data como Apache Spark o Hadoop (procesamiento distribuido en tiempo real).
- Librerías del ecosistema Python: **Pandas, NumPy, Matplotlib/Seaborn** (gráficos), **TensorFlow, PyTorch** (deep learning), **scipy** (medidas estadísticas avanzadas).
- **Herramienta de la cursada** ☒: **Google Colab** (en la nube, notebooks con **Python + Markdown**). Hay que "**Guardar una copia en Drive**" para editar. En el TP se puede usar cualquier lenguaje/entorno.

2. ? Conceptos estadísticos fundamentales

[? Volver al índice](#)

2.1 Ley de los grandes números (LGN) ?

- Jacob Bernoulli, siglo XVII.
- La **frecuencia relativa** de un evento **converge a su probabilidad teórica** al **aumentar el número de ensayos**.
- En inferencia: al crecer la **muestra**, la **media muestral** se aproxima a la **esperanza (valor esperado) poblacional**.

Lecturas del docente ?:

- **No se pueden sacar conclusiones definitivas de fenómenos masivos a partir de casos aislados** (velocidad promedio del ser humano $\neq$ velocidad de atletas olímpicos; hay que armar una muestra **representativa**).
- **Cuanto más grande la muestra, mejores las estimaciones**.
- Vínculo con IA: el salto de **GPT-2 a GPT-3** fue el **volumen de datos** de entrenamiento; "**a pequeña escala la IA no funciona**".
- Aplicación en clase (04/09): repetir el experimento lista vs. NumPy muchas veces y **promediar**.

2.2 Teorema central del límite (TCL) ?

- Desarrollado entre los **siglos XVIII y XIX**; reformulado **hasta el XX**.
- Dada una población con **cualquier distribución**, la **distribución de las medias muestrales tiende a una normal** al aumentar el tamaño de la muestra, **siempre que la varianza poblacional sea finita**.

Ejemplo del docente ? (semillas, Fisher): se compara una semilla original con una modificada genéticamente. Se toman muestras, se estima la **media de producción (toneladas)** de cada una y esas medias siguen una distribución normal. Como se conocen las propiedades de la normal, se **testea si una semilla rinde mejor que otra** usando media, desvío estándar y el **rechazo de la hipótesis nula**. Si las curvas están muy separadas se ve a simple vista; si se solapan no se puede afirmar.

	Ley de los grandes números	Teorema central del límite
Época	Bernoulli, s. XVII	s. XVIII–XIX (reformulado hasta el XX)
Dice	La media muestral se acerca al valor esperado	La distribución de las medias muestrales tiende a la normal
Condición	Más ensayos / muestra más grande	Muestra grande + varianza poblacional finita
Idea	" A dónde va el número"	" Qué forma tiene " (campana)

? El docente advirtió que **se confunden ambos conceptos** en los exámenes. **Tarea:** investigar **(1)** qué es la LGN y **(2)** el **vínculo entre el TCL y el test de hipótesis**.

3. NumPy — manipulación eficiente de vectores

[Volver al índice](#)

Pregunta de parcial: ¿por qué es tan importante NumPy? ¿Cuáles son las características y la importancia de `ndarray`? (No toma funciones de memoria ni código; sí la **importancia conceptual**).

3.1 ¿Qué es?

NumPy = Numerical Python. Sirve sobre todo para variables **cuantitativas** (discretas y continuas), pero **optimiza** los procedimientos más allá de lo numérico.

Características generales:

- Desarrollada en **C** (lenguaje de **bajo nivel**), orientada a **arrays multidimensionales** y gran cantidad de información.
- Recursos para **matemática, álgebra lineal** y diversas disciplinas científicas.
- Código abierto, multiplataforma, optimizada, sintaxis de alto nivel.**

¿Por qué importa que esté en C?

- C es **tipado y compilado** y permite **manipular la memoria** con mucha más precisión (Python, de alto nivel, no).
- Resultado: operaciones matemáticas y algebraicas **más veloces y optimizadas** con grandes volúmenes.
- Las **dos ventajas** que se buscan en informática: **mayor velocidad** y **menor espacio en memoria** (relacionadas pero distintas).

Casos de uso: Big Data, estadística avanzada, álgebra lineal, procesamiento del lenguaje natural, procesamiento de imágenes.

Ecosistema (todas usan NumPy "por detrás"): computación cuántica, **Pandas**, procesamiento de señales, imágenes, **grafos y redes (NetworkX)**, astronomía, psicología cognitiva, bioinformática, inferencia bayesiana, análisis matemático, química, geografía, arquitectura, ingeniería. **Deep learning/ML: TensorFlow y PyTorch.**

Casos de estudio: primeras imágenes de **agujeros negros, ondas gravitacionales**, análisis deportivo, posiciones de animales con aprendizaje profundo.

Aunque uses Pandas y no NumPy directamente, **NumPy sienta las bases.**

3.2 La clase `numpy.ndarray`

Principal clase y base de todas las operaciones matemáticas numéricas de NumPy.

Lista de Python	<code>ndarray</code>
Mutable y heterogénea: se puede cambiar un entero por un flotante, tupla, set o lista → hay que reservar espacio de más	Tamaño fijo una vez instanciado
Creada priorizando legibilidad (la optimización quedó en segundo plano)	Todos los elementos del mismo tipo (y tamaño)
Puede recorrer memoria innecesariamente por posibles cambios futuros	Memoria contigua y reservada estrictamente para esos elementos
—	Excepción: un vector de objetos permite distinto tipo/tamaño

- `ndarray` es un "**parche**" a un problema de Python: combina **lo mejor de dos mundos** (alto nivel legible + ventajas del bajo nivel de C).

- Facilita operaciones matemáticas avanzadas y es ampliamente usada por otros paquetes.

3.3 Atributos y métodos

Atributo	Devuelve
<code>ndim</code>	Nº de dimensiones (fijo)
<code>shape</code>	Tupla con elementos por dimensión
<code>dtype</code>	Tipo de datos (ej. <code>int64</code>)
<code>size</code>	Cantidad total de elementos
<code>itemsize</code>	Bytes por elemento
<code>data</code>	El buffer con los elementos
<code>T</code>	Transpuesta

Método / función	Qué hace
<code>flatten()</code>	Pasa a una dimensión
<code>reshape()</code>	Cambia la forma
<code>sum()</code> , <code>mean()</code> , <code>std()</code>	Suma, media, desvío estándar
<code>zeros()</code> , <code>ones()</code> , <code>empty()</code>	Arrays de ceros, unos, valores sin inicializar
<code>arange()</code>	Como <code>range()</code> pero permite decimales
<code>linspace()</code>	Intervalos regulares
<code>sort()</code>	Ordena (ascendente por defecto)
<code>concatenate()</code> , <code>expand_dims()</code>	Concatenar, agregar dimensiones

🔗 Para qué sirve `flatten`: trabajar en **una dimensión es más veloz**; muchos algoritmos de IA **apilan las columnas de una matriz** en un vector. `reshape/flatten` cambian el tamaño **sin "barbaridades" en memoria**.

🔗 `empty()` no inicializa: contiene "basura" de memoria. Por convención `import numpy as np`.

3.4 Experimento de la clase 🔗 (lista vs. NumPy)

- Elevar al cuadrado **1.000.000 de elementos**: lista $\approx 0,0457$ s vs. NumPy $\approx 0,0013$ s $\rightarrow \approx 32,8$ veces más **rápido** (otras corridas: 27x, 85x; en Colab $\sim 50x$).
- **Conclusiones**: (1) NumPy **es más rápido**; (2) **LGN**: con más corridas el promedio se acerca a la diferencia real; (3) **TCL**: la distribución de los resultados tendría **forma de campana**.
- **Memoria**: para 10.000 elementos, la lista ≈ 360.056 bytes y el array ≈ 80.000 bytes (`int64`, 8 bytes $\times$ 10.000).

3.5 Imágenes como arrays 🔗

- **Blanco y negro**: una sola **matriz**. **Color**: tres matrices superpuestas (**RGB**); ej.: amarillo = rojo + verde. Una imagen de $5 \times 5 = 25$ píxeles.
- Por eso NumPy es clave en **procesamiento de imágenes**; la IA que genera imágenes **opera matemáticamente con matrices**.

4. ? Pandas — análisis de datos estructurados

[? Volver al índice](#)

4.1 ¿Qué es?

- Librería para **DataFrames** (estructuras tabulares). Creada por **Wes McKinney** (2008), autor de *Python para análisis de datos* (bibliografía obligatoria).
- ? Intentó **imitar a R**. Trabaja con **datos estructurados**. Usa **ndarray** de NumPy para las variables numéricas.
- **Código abierto, multiplataforma, optimizada, sintaxis de alto nivel.**
- ? Maneja también variables **ordinales, fechas y texto**, y permite **unir tablas**. Convención: `import pandas as pd`.

Funciones más usadas: `read_csv()`, `read_excel()`, `read_json()`, `DataFrame()`, `to_datetime()`, `merge()`.

4.2 Estructuras básicas

Estructura	Descripción
Series	Vector unidimensional etiquetado , de cualquier tipo, basado en <code>ndarray</code>
DataFrame	Estructura bidimensional (tabla), construida sobre Series

? **Series = dos vectores 1D en paralelo: valores** (usa `ndarray`) y **etiquetas/índice** (tipo `Index`, propio de Pandas, no `ndarray`).

- **Atributos de Series:** `index`, `values`, `name` (opcional), `is_unique` + la mayoría de los de `ndarray` (**no** `data`, `itemsizes`, `strides`).
- **Métodos de Series:** casi todos los de `ndarray` (**excepto** `flatten` y `reshape`) + `head()`, `describe()`, `dropna()`, `apply()`...
- ? **¿Por qué no `flatten/reshape`?** No se pueden unificar **etiquetas con valores** ni **columnas de distinto tipo**; estadísticamente **no es correcto** porque el tratamiento de una variable cualitativa, ordinal o cuantitativa **es distinto**.
- ? `describe()` devuelve: **conteo, media, desvío estándar, mínimo, Q1, mediana, Q3, máximo**.
- **Atributos de DataFrame:** `shape`, `columns`, `dtypes` (? tipo de las **columnas**; texto y diccionarios figuran como **object**). **Métodos:** `to_csv()`, `to_excel()`, `head()`, `info()`, `groupby()`.

4.3 Selección de columnas

Por nombre	Por posición (iloc)
<code>df.id</code> o <code>df["id"]</code>	<code>df.iloc[:, 1]</code>
<code>df[["id", "damage"]]</code>	<code>df.iloc[:, 1:4]</code>

4.4 Filtrado de filas

Por posición	Según condiciones
<code>df.iloc[2, :]</code>	<code>df.loc[df.damage == 3, ["id", "damage"]]</code>
	<code>df.query("damage > 2")</code> (? estilo SQL)

- ? **A la izquierda las filas, a la derecha las columnas.** `:` = "todas".

- Python cuenta desde 0 y el final del rango **no se incluye**: `iloc[:,1]` es la 2.ª columna; `iloc[:,1:4]` son las posiciones 1, 2 y 3; `iloc[2,:]` es la 3.ª fila.

4.5 Índices: `loc` vs `iloc`

- Los **índices simplifican el acceso** y permiten **filtrar** (ej.: si el análisis es sobre Avellaneda, no sirven datos de Lanús, Tigre o La Matanza).
- `loc` = nombres/etiquetas · `iloc` = posiciones numéricas.

4.6 Fechas y texto

- `pd.to_datetime()` + accesor `dt` → año, mes, día.
- Accesor `str` → `lower()`, `upper()`, `split()`, `replace()`, `splice()` *...
> *La diapositiva dice `splice()`; probablemente sea `slice()`.

4.7 Datos usados en clase

- **Kaggle** (y `kagglehub`): comunidad de IA y ML con **~734.000 datasets**, notebooks, modelos preentrenados y **competencias** con premios (algoritmos de Netflix salieron de competencias así).
- Dataset de **League of Legends** (ID, nombre, título, dificultad, daño, etc.). Otras librerías con datasets: Keras.
- El libro usa datasets de R como `iris` y `mtcars` (ver códigos en §5–§7).

5. Data cleaning — limpieza y preparación

[Volver al índice](#)

Data cleaning = paso previo al análisis.

5.1 Contexto (ETL) y etapas

- Proceso ETL: **cargar, transformar y volver a guardar** los datos.
- Etapas: **1** Recolección → **2** Almacenamiento → **3 Limpieza y preprocesamiento** → **4** Análisis → **5** Visualización y/o modelado. [RALAV](#).
- El analista normalmente **empieza en la etapa 3**, pero **las etapas están interconectadas**.
- Los datos reales **tienen problemas**. Los **atípicos/inconsistentes** no dan indicio previo (en el 99 % de los casos parecen normales).
- **Trabajo del analista:** **detectar** los problemas, **identificar qué sucede** y, si corresponde, **plantear una solución**.

Problemas más comunes: valores nulos, duplicados y atípicos/inconsistentes.

5.2 Valores duplicados

- **Problema:** **sobrerrepresentación** → **conclusiones sesgadas**. **Solución:** dejar uno solo → `df.drop_duplicates()`.
- **Ojo con los "grises"** (ejemplo: DataFrame con ID, nombre y localidad; 7 registros; 2 repetidos):
 - Juan con el **mismo ID** pero distinta localidad (¿doble carga o persona distinta?).
 - María en la misma localidad: puede haber **dos personas distintas**.
 - Consultar a quien hizo el relevamiento; si no, **definir un criterio** (por ID, o por **nombre + localidad**). En pandas se eligen la/s columna/s.

5.3 Valores perdidos o "no respuesta" (datos faltantes)

- **No respuesta parcial:** registros con **campos vacíos**. Problema **subestimado**, sobre todo en **encuestas de opinión pública** y en la inferencia tradicional; en ML/modelado sí se le presta atención.
- En R se marcan como **NA**. En el análisis **univariado** los faltantes simplemente se omiten; en el **multivariado**, **un solo dato faltante puede obligar a descartar toda la fila**, reduciendo mucho el tamaño muestral.
- Puede llevar a **conclusiones incorrectas** con tasa de no respuesta alta. **Umbrales orientativos:**

Tasa de no respuesta	Nivel
> 5 %	Empezar a tenerla en cuenta
> 10 %	Importante
> 30 %	Grave (a veces se descarta la variable)

5 – 10 – 30. Lo clave es **detectar el patrón**.

Patrones de la no respuesta

¿Se puede soslayar?	Patrón	Descripción
---------------------	--------	-------------

¿Se puede soslayar?	Patrón	Descripción
✓Sí	Completamente aleatoria	Sin patrón ni asociación con otras variables. No introduce sesgo
✗No	Aleatoria	Hay azar, pero condicionada por otras variables del dataset
✗No	No aleatoria	La no respuesta se explica por la propia variable de interés

Ejemplos 📌 (sensor de temperatura):

- **Completamente aleatoria:** el sensor manda datos por 4G/5G y a veces se cae la señal.
- **Aleatoria:** falla más con **humedad** (relacionada con la temperatura) → **temperatura media subestimada**.
- **No aleatoria:** falla cuando **sube la temperatura** (la propia variable).

Ejemplo numérico 📌 ("semáforo"): encuesta de **1.000 casos**, **200 no respuestas = 20 %**. Ingreso medio por grupo etario: 16–25: **\$500.000**; 26–40: **\$800.000**; 40–65: **\$1.200.000**; 65+: **\$1.100.000**.

Semáforo	Escenario	No respuesta por grupo etario	Lectura
🟢 Verde	Completamente aleatoria	19 % · 20,5 % · 18,8 % · 20,3 % (≈20 %; se podría hacer un chi-cuadrado)	Sin sesgo claro
🟡 Amarillo	Aleatoria (asociada a la edad)	15 % · 18 % · 23 % · 30 %	Faltan justamente ingresos altos → media de ingreso sesgada hacia abajo . Hay que tratarla
🔴 Rojo	No aleatoria (asociada al ingreso)	Mayor no respuesta en el grupo de mayor ingreso (40–65)	Problema circular: la causa de la no respuesta es lo que quiero estimar

- 📌 **Clave:** en la **aleatoria** puedo **apoyarme en otras variables** para corregir; en la **no aleatoria** no.
- 📌 **No hay técnica infalible** que diga el patrón: es una **definición conceptual del analista**. Los nombres "aleatoria / no aleatoria" no son los mejores (hay azar en ambos); "no aleatoria" alude a que **depende de sí misma**.
- 📌 Hay que ver **las variables del dataset y la variable objetivo**, no solo grupos artificiales.
- 📌 **Supuesto del muestreo:** casos con características semejantes **tienden a comportarse parecido** (dos personas de Puerto Madero se parecen más entre sí que con uno de Florencio Varela).

Tratamientos

Caso	Solución
Completamente aleatoria	Eliminar registros → <code>df.dropna()</code>
Aleatoria o no aleatoria	Depende de tasa y características: imputación, reponderación , modelos

Alternativas del libro 📌:

1. **Listwise deletion (eliminación por casos):** borrar la fila; recomendable solo si la proporción de individuos con faltantes es muy baja (p. ej. < 5 %).
2. **Imputación por media/mediana:** simple, pero **subestima la varianza y altera las covarianzas**.
3. **Imputación múltiple y métodos basados en modelos:** K-vecinos más cercanos, máxima verosimilitud, etc.

```
# Código 2.19 (Libro): detección e imputación en R
library(mice)
colSums(is.na(mis_datos))           # faltantes por variable
datos_completos <- na.omit(mis_datos) # Listwise deletion
datos_imputados <- mice(mis_datos, m = 5, method = "pmm", seed = 123)
base_final <- complete(datos_imputados)
```

Técnicas de imputación 📌:

- **Medias condicionadas** (la más **básica**): armar **grupos**, calcular la media de cada uno y **asignarla**.
- **Modelos de aprendizaje automático**: predecir con **muchas variables** (edad, sexo, nivel educativo, localidad, ocupación...).
- **Hot deck**: buscar otro caso con **las mismas características exactas** en algunas variables y **elegir uno al azar**. Las variables usadas deben **estar relacionadas con la variable a imputar** (para ingreso sirven **ocupación** y **nivel educativo**; el **apellido** no).
- **Reponderación** (ver ponderadores).

Ponderadores 📌 (se usan en el TP final)

- **Ponderador** = cuántos casos de la población representa cada elemento muestral = $\text{población} / \text{muestra}$.

Grupo	Población	Muestra	Ponderador
1	1.000.000	200	5.000
2	900.000	190	≈ 4.737
3	800.000	210	≈ 3.810
4	500.000	195	≈ 2.564
5	300.000	205	≈ 1.463

- **Estimaciones más precisas**: en el grupo de **menor ponderador** (universo más chico; un atípico mueve menos). No depende solo de la LGN sino del **tamaño del universo**.
- **Reponderación**: con 10 % de no respuesta, los 200 casos pasan a **180** y deben representar **todo el universo** → ponderador $1.000.000 / 180 \approx 5.555$. Se ajustan para que los **respondentes representen también a los no respondentes**.
- Se puede complejizar: subdividir por sexo y edad ($8 \times 5 = 40$ **ponderadores**); el INDEC usa **muestreo complejo polietápico** (ponderador = producto de probabilidades de selección de cada etapa).
- **EPH** (microdatos del TP): trae **varios ponderadores**; hay que saber **cuándo usar cada uno**.

Conclusión: decisión metodológica del analista, sencilla o compleja según objetivos y características de la no respuesta. **No hay respuesta automática.**

5.4 Valores atípicos (outliers) e inconsistentes 📌

	Atípico	Inconsistente
Definición	Dato alejado del patrón general , pero posible/válido	Dato sin coherencia con el conjunto o con el conocimiento previo
Tratamiento	No necesariamente se excluye ni modifica; se inspecciona y depende del objetivo	Se corrige o se elimina ; nunca se usa
Ejemplos	Persona de 105 años ; propiedad en Avellaneda cerca del río ; salario del jugador mejor pago del fútbol argentino	Persona de 250 años ; punto fuera del territorio de análisis; valor de tipo distinto

Ejemplos en clase 📌:

- **250 años**: probablemente error de carga (un cero de más); distorsiona la media.
- **Mapa (Properati)**: análisis de **Avellaneda**. **Inconsistentes**: puntos en CABA, La Matanza, Lanús (mal cargados) → **se excluyen**. **Atípicos**: puntos **dentro** de Avellaneda cerca del río, alejados de la masa; válidos, se decide según el objetivo.

- **Depende del objetivo:** el salario de un futbolista de élite no sirve para estimar cuánto pedir en una entrevista, pero **sí** para un **estudio de mercado de alta gama**.
- 105 años: no es común pero **es posible**.

📌 **Atípico = raro pero posible (se analiza). Inconsistente = imposible o incoherente (se corrige o se borra).**

¿Cómo detectar atípicos?

1. **Boxplot** (univariado) 📌: los atípicos aparecen como **puntos alejados de la caja**.
2. **Z-score** 📌: **cuántos desvíos estándar se aleja cada registro de la media**. Mayor Z-score = más atípico. Ej.: edad media **46,9**, desvío **23,4** → la persona de 100 años tiene **Z ≈ 2,38**.
3. **Rango intercuartílico (IQR): Q3 – Q1**, la caja del boxplot.
4. **Aprendizaje automático**.

📌 **Detalle del boxplot (libro)**

La caja se construye con los cuartiles y permite evaluar:

1. **Tendencia central:** la línea dentro de la caja es la **mediana (Q2)**.
2. **Dispersión:** la altura de la caja es el **RI = Q3 – Q1**.
3. **Asimetría:** si la mediana está centrada o desplazada, y el largo relativo de los bigotes.
4. **Atípicos:** los bigotes llegan al mínimo y máximo que **no superen 1,5 × RI**; lo que excede se grafica como punto individual.

Código 2.9 (libro): *boxplot comparativo por categoría*

```
boxplot(iris$Sepal.Length ~ iris$Species,
        main = "Longitud del sépalo según Especie",
        xlab = "Especie", ylab = "Longitud del sépalo",
        col = c("palegreen1", "paleturquoise", "plum2"), border = "gray30")
```

📌 La interpretación del boxplot fue mencionada el 11/09 como pregunta habitual, pero el 25/09 dijo que **gráficos no entran**. Por las dudas, sabé qué es la caja, los cuartiles y los puntos atípicos.

📌 **Estadística robusta en dimensión múltiple (libro, Cap. 2)**

Las medidas clásicas (media, varianza, covarianza de Pearson) son **muy sensibles a atípicos**; en varias dimensiones son difíciles de detectar y provocan:

1. **Enmascaramiento (masking):** un grupo de outliers distorsiona tanto el centroide y la matriz de covarianza que **esconde a otros outliers** verdaderos (solo se revelan al eliminar los primeros).
2. **Inundación (swamping):** las estimaciones distorsionadas hacen que **observaciones normales parezcan outliers**.

Herramientas robustas:

- **Distancia de Mahalanobis:** a diferencia de la euclídea, **pondera por la matriz de covarianzas** (se ajusta a la forma y correlación de la nube de puntos); mide la lejanía respecto al centro.

$$d_m(X, Y) = \sqrt{(X - Y)^t \Sigma^{-1} (X - Y)}$$

- **Vector de medianas:** reemplazo robusto del vector de medias (centroide).
- **MVE (Minimum Volume Ellipsoid):** busca el **elipsoide de menor volumen** que cubra una submuestra mayoritaria (ej. $m = n/2$). Alto punto de ruptura, equivariante ante transformaciones afines.
- **MCD (Minimum Covariance Determinant):** busca el subconjunto de tamaño m (de n datos) cuya **matriz de covarianzas tenga el menor determinante**. Se implementa con el algoritmo **FAST-MCD** (`cov.rob(..., method = "mcd")`), paquete **MASS**.

- **LOF (Local Outlier Factor):** medida basada en **densidad** con los k vecinos más cercanos (paquete **DMwR**, **lofactor**).

Control univariado vs. multivariado ☒: el univariado (límites en una variable) detecta si un dato excede los límites pero **no informa sobre la estructura**. El multivariado (dispersión + **elipses de confianza**, normal bivariada) detecta observaciones que, aun dentro de los rangos de X_1 y X_2 por separado, **rompen el patrón de interacción** del grupo.

6. 📊 Transformación de datos

🔗 Volver al índice

"En algunas ocasiones, para **optimizar el análisis** de la información, es conveniente **realizar transformaciones a los datos**. Pueden ser **por filas o por columnas** (por **individuos** o por **variables**).". (Chan, Badano y Rey, 2019)

Objetivos más usuales: (1) hacer **comparables las magnitudes**; (2) **modificar la escala** de medición; (3) **satisfacer alguna propiedad estadística** (necesaria para ciertos modelos). 📌 Neutralizan diferencias de escala o sesgos de medición y garantizan comparabilidad antes de aplicar algoritmos multivariados.

6.1 Transformaciones por variables (columnas)

📌 Evitan que variables con mayor magnitud o varianza **dominen** el análisis (ej. PCA o clustering), sobre todo con unidades distintas (kg, m, miles de pesos).

Nombre	Fórmula	Para qué
Centrado 📌 (mean centering)	$x'_{ij} = x_{ij} - \bar{x}_j$	Traslada el origen al centro de gravedad de la nube; media 0, conserva la varianza
Z-score (estandarización / tipificación)	$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$ (en clase: $Z = \frac{(X - \mu)/\sigma}{1}$)	Media 0 y varianza 1 ; adimensional; exagera las distancias → útil para detectar atípicos
Min-max (máx-mín)	$x'_{ij} = \frac{x_{ij} - \min(X_j)}{\max(X_j) - \min(X_j)}$	Lleva a [0, 1] conservando proporcionalidad de distancias
Logarítmica	$x' = \log(x + c)$ (en clase: $\log(X + 1)$)	Reduce la influencia de atípicos ; corrige asimetría a derecha
Raíz cuadrada 📌	$x' = \sqrt{x}$	Útil para conteos (Poisson)
Box-Cox 📌	familia de potencias λ	Halla la mejor potencia λ para normalizar la variable

- 📌 **Consideración robusta del Z-score:** asume que media y desvío representan bien centralidad y dispersión. Con fuerte asimetría o atípicos se distorsionan; alternativa: **mediana** en lugar de la media y **MAD** o **IQR** en lugar del desvío.
- 📌 Asimetría positiva (variables económicas o biológicas) → transformaciones no lineales (log, raíz, Box-Cox) para acercar a la normal.

- 📌 **La min-max "no es una normalización"** en el sentido de la distribución normal; es una transformación máximo-mínimo.
- 📌 **Log natural:** el exponente al que hay que elevar e para obtener ese número; es la **inversa de la exponencial**.
- 📌 **Ejemplo del efecto sobre valores 4 y 10:**

- Original: el 10 es **2,5 veces** el 4.
- **Logarítmica:** $10 \approx 2,4$, $4 \approx 1,6$ → el 10 vale solo $\approx 50\%$ más (los atípicos **pierden influencia**).
- **Min-max:** $10 = 1$, $4 \approx 0,33$ → el 10 vale **el triple**.
- **Z-score:** separa mucho los valores (el 4 negativo, el 10 $\approx +1,4$).

- 📌 La log se usa en modelos que funcionan mejor con ciertas distribuciones (ChatGPT suele sugerirla para el TP y "tiene lógica, no es un capricho").

```
# Código 2.18 (Libro): estandarización
datos_estandarizados <- scale(mtcars[, 1:4]) # media 0, varianza 1
```

```
apply(datos_estandarizados, 2, mean)
apply(datos_estandarizados, 2, sd)
```

Transformaciones de tipo de variable:

Transformación	Ejemplo
Cuantitativa → ordinal	Edad en años → "joven", "adulto", "anciano"
Ordinal/categórica → cuantitativa	Asignar valores numéricos (arbitrarios o por algoritmos)
String → datetime	Texto a fecha (<code>to_datetime</code>)

☞ Hoy **se puede transformar cualquier cosa**: los modelos de IA **transforman palabras en vectores** y hacen transformaciones algebraicas.

6.2 Transformaciones por individuo (filas)

Homogeneizan a los individuos, neutralizando tendencias subjetivas o diferencias de tamaño. ☞ Frecuentes en ecología (abundancia de especies), química (composición de mezclas) y análisis de texto.

a) Neutralización de jueces (clase + libro):

$$T(x) = \begin{cases} \frac{x - \bar{x}}{x_{max} - \bar{x}} & \text{si } x > \bar{x} \\ \frac{x - \bar{x}}{\bar{x} - x_{min}} & \text{si } x < \bar{x} \end{cases}$$

- Se usa la media, máximo y mínimo **del individuo (juez)**; deja valores **relativos a su propia media**. Las puntuaciones superiores a la media resultan **positivas** (escala: tramo superior) y las inferiores **negativas** (escala: tramo inferior).
- ☞ **Jurados** (Polino vs. Moria Casán; Charlie Sheen en EE. UU.): un jurado "duro" (1, 2, 4) y uno "generoso" (6, 7, 10) usan criterios distintos; transformados a la misma escala, **el 2 de Polino es "más valioso" que el 7 de Moria Casán**.
- ☞ Otro ejemplo: notas de **Matemática** (exigente) vs. **Legislación** (más "fácil").
- ☞ Los jueces pueden puntuar sistemáticamente alto/bajo o usar rangos distintos (1–10 vs. 4–7).

b) Relativización por el total (perfiles) ☞: convierte frecuencias absolutas en **composiciones proporcionales** (la suma de la fila es 1). Ej.: una muestra de suelo más grande tiene conteos mayores en todas las especies; al relativizar se compara la composición.

$$x'_{ij} = \frac{x_{ij}}{\sum_{j=1}^p x_{ij}}$$

c) Normalización vectorial (norma euclídea) ☞: todos los vectores-individuo quedan de **longitud 1** (proyectados sobre una hipersfera unitaria).

$$x'_{ij} = \frac{x_{ij}}{\sqrt{\sum_{j=1}^p x_{ij}^2}}$$

7. ? Análisis estadístico de datos

[? Volver al índice](#)

7.1 Organización de los datos

Hay que **ordenar y organizar** la base para facilitar la **comprensión e interpretación**; los **datos crudos** pueden resultar **inabordables** (miles de filas, cientos de columnas). ? La **estadística es la herramienta**; se empieza con una **primera exploración por análisis de frecuencias**.

7.2 Análisis de frecuencias

Datos	Cómo
Cualitativos	Conteo de veces que se repite cada categoría
Cuantitativos	Si la variable no es discreta hay que usar intervalos de clase (ej.: 0–16, 17–30, 31–50, 51–65, 65+)

- Tablas de distribución de frecuencias **absolutas, relativas y porcentuales**.
- ? **Ejemplo (League of Legends, 172 personajes)**: 49 luchadores (**28,5 %**), 37 magos (**21,5 %**), 28 marksman, 24 tanques, 17 asesinos, 17 apoyo.
- ? El conteo ("contar cabezas") es **la forma más primitiva** de estadística, pero sirve de primera aproximación.

7.3 Medidas descriptivas univariadas (una variable a la vez)

? Tendencia central ?

- **Resúmenes**: representan un conjunto de valores **con un solo valor** ("hay información que se escapa").
- **Media aritmética** (suma / cantidad): promedio clásico, **muy sensible a extremos (no robusta)**. **Mediana** (valor central con datos ordenados; divide al 50 %): **robusta**. **Moda** (valor o intervalo de mayor frecuencia).
- **Media geométrica** ? : **multiplica** los valores y calcula la **raíz enésima**; útil con **valores extremos altos**: da un valor **más bajo** que la aritmética.
- **Media podada (alfa-podada)** ?? : **quita un porcentaje de extremos** (ej. 5 % más bajo y 5 % más alto) y calcula la media (**trim_mean** de scipy).

Ejemplo de clase ? (Riot Points de LoL):

Medida	Valor
Media aritmética	711,73
Media geométrica	662
Media podada	740
Mediana	790
Moda	880
Q1 / Q3	585 / 880

- **Lectura**: la media podada **es más alta** que la aritmética → **atípicos hacia abajo**. Asimetría **–1,08**. Orden: **media < mediana < moda**.
- ? Casi todo es categórico; solo **Riot Points y Blue Essence** podrían tratarse como continuas.

- ¿ Un ingreso muy alto (ej. \$15–20 millones) es **real** y no se quiere excluir, pero se puede usar media geométrica para que no condicione tanto. "Un analista debe conocer estas herramientas."

¿ Posición ¿

Dividen el conjunto ordenado **en partes iguales (estadísticos de orden; cuantiles)**.

Medida	Divide en...	Cortes
Mediana	2 partes	1
Cuartiles	4 partes	3 (Q1, Q2, Q3)
Quintiles	5 partes	4
Deciles	10 partes	9
Percentiles	100 partes	99

¿ **PREGUNTA TRAMPA:** "¿Qué tipo de medida es la mediana?" → **AMBAS: tendencia central Y posición.**

La **mediana es robusta** ¿: no se ve afectada por valores extremos (da igual que el mayor sea 9.990 o 15.000 millones); **más robusta que la media e incluso que la geométrica**; sirve en **muestras pequeñas**.

¿ Dispersión ¿

Indican la **variabilidad**; la mayoría cuantifica la **concentración de datos alrededor de una medida de posición o de tendencia central**.

Medida	Descripción
Rango	Máximo – mínimo (sensible a extremos)
Varianza	Suma de diferencias de cada valor con la media, al cuadrado (sensible a extremos)
Desvío estándar	Raíz cuadrada de la varianza → vuelve a las unidades originales
Coefficiente de variación	Desvío estándar / media; compara dispersión entre conjuntos con distintas medias o unidades
Rango intercuartílico (IQR / RI)	Q3 – Q1 (robusta, basada en posición)
MAD	Mediana de los desvíos absolutos respecto de la mediana (robusta); ¿ normalizada como MADN

- ¿ Varianza, desvío y coeficiente de variación son **transformaciones de la misma medida**.
- ¿ **Varianza poblacional: sobre N. Varianza muestral: sobre N – 1** → resultado **más alto** que **evita subestimar la dispersión**.

¿ Forma: asimetría y curtosis

- **Asimetría:** indica si la distribución es **simétrica, de asimetría positiva (a derecha) o negativa (a izquierda)** respecto de la media.
 - **Negativa:** pocos valores extremos a la izquierda; **moda > mediana > media**; al recortar extremos la media se acerca a la mediana y a la moda.
 - **Coefficiente de Fisher(–Pearson)** (el de los Riot Points: –1,08). **Coefficiente de Pearson:** (media – moda) / desvío estándar. **Coefficiente de Bowley:** usa **cuartiles**.
- **Curtosis:** grado de **apuntamiento: leptocúrtica, mesocúrtica, platicúrtica**.

- **Reflexión clave: los datos no "hablan solos".** Las estimaciones **se construyen** con metodologías y **definiciones arbitrarias**; distintas metodologías dan distintos resultados. Hay que tomar los datos "con pinzas".

Gráficos univariados (libro; visualización no entra)

- **Histograma:** discreto y **depende de los intervalos de clase (bins)**; el código 2.8 lo genera variando la cantidad de clases.
- **Curva de densidad suavizada (KDE):** estimación continua y suavizada de la distribución subyacente, menos dependiente de los bins.
- **Tallo y hojas (stem-and-leaf): no pierde los datos originales;** separa cada número en "tallo" y "hoja"; se imprime en consola como histograma rotado.

```
# Código 2.10: histograma + curva de densidad
densidad <- density(iris$Sepal.Length)
hist(iris$Sepal.Length, prob = TRUE, main = "Histograma y Curva de Densidad",
     xlab = "Longitud del sépal", ylab = "Densidad",
     col = "lightsteelblue", border = "white")
lines(densidad, lwd = 2, col = "indianred1")

# Código 2.11
stem(iris$Sepal.Length)
```

7.4 Análisis bivariado

- **Dos variables de forma conjunta:** una **independiente** y una **dependiente**; también hay análisis **simétricos**. Ej.: peso según altura, desocupación según aglomerado, ingreso según ocupación.
- **Tabla de frecuencias de doble entrada** (ej.: tipo de héroe × tipo de rango: 14 asesinos cuerpo a cuerpo, 47 luchadores cuerpo a cuerpo, 35 magos a distancia...).
- **Gráfico de dispersión (scatterplot):** eje X e Y, cada punto una observación conjunta (x_i, y_i) ; permite ver si hay relación lineal, no lineal, directa, inversa o independencia.

```
# Código 2.12
plot(iris$Sepal.Length, iris$Petal.Length, main = "Relación entre Longitud de Sépalo y Pétalo",
     xlab = "Longitud del Sépalo", ylab = "Longitud del Pétalo", pch = 19, col = "royalblue")
```

Covarianza

- Variabilidad **conjunta**; asociación **lineal**; **no estandarizada** → depende de la **escala**.
- Clase: $\text{cov}(x, y) = \sum (x_i - \bar{x})(y_i - \bar{y}) / (N - 1)$. Libro: $s_{ik} = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k)$ (la diferencia n vs. $n - 1$ es la de varianza poblacional vs. muestral).
- Es la **misma fórmula que la varianza**, con dos variables distintas; si se reemplaza y por x se obtiene la **varianza**.
- Signo (s_{ik}): $s_{ik} > 0$ asociación lineal **positiva**; < 0 **negativa**; $= 0$ **ausencia** de asociación lineal.
- **Defecto:** difícil de interpretar (valores como -17, -0,15, -459 o 331.556 según la escala).

Propiedades:

- $\text{Cov}(X, X) = \text{Var}(X)$.
- Distributiva: $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$.
- Con matrices: $\text{Cov}(AX, BY) = A \cdot \text{Cov}(X, Y) \cdot B^t$.
- **Dependencia lineal:** si una variable es función lineal exacta de otra (ej. $Y = -2X + 3$), $\det(\Sigma) = 0 \rightarrow$ **matriz singular** (información redundante).
- **Dependencia de unidades:** $\text{Cov}(aX, cY) = ac \cdot \text{Cov}(X, Y)$.

Correlación

Variables	Medida
Númericas	Pearson : estandariza la covarianza → valores entre -1 y 1 ; asociación lineal (no capta relaciones cuadráticas, cúbicas...)
Númericas (alternativa)	Spearman : usa rangos → menos sensible a extremos
Catógoricas	V de Cramer
Númerica + catógorica	t de Student o coeficiente eta

$r_{ik} = \frac{s_{ik}}{\sqrt{s_{ii}\sqrt{s_{kk}}}$: es la **covarianza de las variables estandarizadas (puntajes Z)**. $|r_{ik}| \leq 1$; con $r_{ik} = \pm 1$ los datos yacen exactamente sobre una **recta**. Cercano a 1: fuerte asociación lineal positiva; cercano a -1: fuerte negativa; cercano a 0: ausencia de relación lineal.

Cómo interpretar una matriz de correlación

- Valores de **-1 a 1**. **Positivo** = crecen juntas; **negativo** = **correlación inversa** (uno crece, el otro decrece), **NO** significa "no hay correlación"; **cerca de 0** = **falta de asociación**.
- La **diagonal siempre vale 1**.
- Se visualiza con **mapa de calor (heatmap, Seaborn)**;  en R, **correlogramas (corrplot)**: **azul** = **positiva**, **rojo** = **negativa**, intensidad proporcional a la magnitud.
- Ejemplo (LoL)**: asociación positiva más fuerte: **Blue Essence – Riot Points (0,84)** (dos monedas para el precio de los personajes). Casi sin asociación: **utility–difficulty (0,02)**, **control–ID**.
- Clusterización** : reordena las variables de modo que las de alta correlación quedan juntas (arriba a la izquierda).

7.5 Análisis multivariado

- Más de dos variables** a la vez. **Registros** = **filas (n)**; **variables** = **columnas (p)**.
- Matriz de covarianzas** Σ : simétrica; **diagonal** = **varianzas** (s_{ii}), fuera de la diagonal las covarianzas. **Matriz de correlaciones** R : simétrica con **unos en la diagonal**.
- Traza** $tr(A) = \sum a_{ii}$ (suma de la diagonal):
 - $tr(\Sigma)$ = suma de todas las varianzas → **variabilidad total** ("magnitud" del problema).
 - $tr(R) = p$ (número de variables), porque la diagonal son unos.
- Complejidad** (cantidad de parámetros): $2p + p \cdot (p - 1)/2 \rightarrow p$ medias + p varianzas + $p(p-1)/2$ covarianzas. Ej.: $p = 4 \rightarrow 8 + 6 = 14$; $p = 5 \rightarrow 20$.
-  Al **agregar variables el análisis se vuelve más costoso** (tiempo, memoria, energía). El docente lo describió como "medio exponencial";  matemáticamente el término dominante es **cuadrático** (p^2).
- Técnicas avanzadas** (final del cuatrimestre): **componentes principales**, **correspondencias** ( no entran), **clusterización**, **modelado** ("poquito").

7.6 Ejercitación del libro (Cap. 2)

- Transformaciones**: perfiles y estandarización (por columnas y por filas) de puntajes de candidatas evaluadas por jueces.
- Limpieza de datos**: valores extraños con tablas de frecuencias, coordenadas paralelas y boxplots (edad, tiempo online); errores de tipeo, valores salvajes; pertinencia de media vs. mediana.
- Relaciones bivariadas**: variables zoométricas de **gorriones**; dispersión condicionada por supervivencia (la relación conjunta explica más que cada variable aislada); histogramas, boxplots comparativos, matrices de dispersión.
- Gráficos de estrellas**: perfiles multivariados (razas de perros por tamaño, peso, inteligencia...).

5. **Álgebra de covarianzas:** cálculo e interpretación de Σ , R y sus trazas; efecto de agregar variables derivadas linealmente sobre la traza y la singularidad.
6. **Estadística robusta:** inyectar outliers enmascarados y comparar MCD/MVE contra estimadores clásicos.

8. ? Resumen rápido (tablas para repasar)

[? Volver al índice](#)

8.1 Qué hacer con cada problema de datos

Problema	Solución
Duplicados	<code>drop_duplicates()</code> (definir criterio: ID o combinación de columnas; consultar la fuente)
Nulos completamente aleatorios	<code>dropna()</code> / listwise deletion
Nulos aleatorios / no aleatorios	Imputación (medias condicionadas, hot deck, modelos ML) o reponderación
Atípicos	Detectar (boxplot, Z-score, IQR; multivariado: Mahalanobis, MCD/MVE, LOF); no necesariamente excluir
Inconsistentes	Corregir o eliminar siempre

8.2 NumPy vs. Pandas

	NumPy	Pandas
Estructura	<code>ndarray</code> (multidimensional)	<code>Series</code> (1D etiquetada) y <code>DataFrame</code> (2D)
Tipos	Un solo tipo por array	Distinto tipo por columna
Base	Escrita en C	Usa <code>ndarray</code> para valores numéricos
Enfoque	Cálculo numérico, álgebra	Datos tabulares/estructurados
<code>flatten/reshape</code>	Sí	No (no se pueden aplanar Series/DF)

8.3 Medidas: de qué "familia" son

Familia	Medidas
Tendencia central	Media, mediana , moda (+ geométrica, podada)
Posición	Mediana , cuartiles, quintiles, deciles, percentiles
Dispersión	Rango, varianza, desvío, coef. de variación, IQR , MAD
Forma	Asimetría (Fisher–Pearson, Pearson, Bowley), curtosis
Asociación	Covarianza, correlación (Pearson, Spearman), V de Cramer, t de Student, eta

8.4 Transformaciones

Transformación	Fórmula
Centrado	$x - \bar{x}$
Z-score	$(X - \mu)/\sigma$
Min-max	$(X - X_{\min})/(X_{\max} - X_{\min})$

Transformación	Fórmula
Logarítmica	$\log(X + 1)$
Por individuo (jueces)	$(x - \bar{x}) / (x_{\max} - \bar{x})$ si $x > \bar{x}$; $(x - \bar{x}) / (\bar{x} - x_{\min})$ si $x < \bar{x}$
Perfiles / norma euclídea	$x / \sum x \cdot x / \sqrt{\sum x^2}$

8.5 Patrones de no respuesta (semáforo)

Color	Tipo	Se explica por...	Solución
?	Completamente aleatoria	Nada (azar/factor externo)	Eliminar
?	Aleatoria	Otra variable del dataset	Imputar / reponderar usando esa variable
?	No aleatoria	La propia variable objetivo	Problema circular, el más grave

8.6 Σ vs. R

	Covarianzas Σ	Correlaciones R
Diagonal	Varianzas	Unos
Unidades	Dependen de las unidades	Adimensional (-1 a 1)
Traza	Suma de varianzas	Igual a p

9. 📖 Mnemotecnias

[📖 Volver al índice](#)

- **5 V de Big Data:** Volumen, Velocidad, Variedad + Veracidad y Valor.
- **Estadística vs. minería:** *DE-CO-CON-opcional* vs. *IN-EX-SIN-indispensable*.
- **Variables:** Categórica → Ordinal → Discreta → Continua ("no ordena → ordena → cuenta → mide").
- **Etapas:** Recolectar → Almacenar → Limpiar → Analizar → Visualizar (**RALAV**).
- **Problemas de limpieza:** Nulos, Duplicados, Atípicos/inconsistentes.
- **Atípico vs. inconsistente:** "raro pero real" vs. "imposible".
- **Umbrales de no respuesta:** 5 – 10 – 30.
- **La mediana es doble agente:** central y posición.
- **Posición:** 2 · 4 · 5 · 10 · 100.
- **N-1:** "exagera" la dispersión para no subestimarla.
- **Media podada > aritmética** ⇒ atípicos hacia **abajo** (asimetría negativa).
- **loc = etiquetas · iloc = posiciones.**
- **Correlación:** diagonal = 1; negativo ≠ "nada"; 0 = sin asociación.
- **n = filas · p = columnas.**
- **LGN = a dónde va · TCL = qué forma tiene.**
- **Ponderador = población / muestra.**
- **Masking = esconde outliers · Swamping = inunda de falsos outliers.**

10. Preguntas de autoevaluación

[Volver al índice](#)

(Tapá las respuestas y contestá de memoria. Las marcadas  son las que el docente mencionó.)

-  **¿Qué relación/diferencias hay entre análisis estadístico y minería de datos?** → Cuadro §1.6 (deductivo vs. inductivo, confirmatorio vs. exploratorio, con vs. sin supuestos, informática opcional vs. indispensable) + explicación.
-  **¿Cuáles son las 3 V del Big Data y cuáles se suelen agregar? ¿Por qué no se define con un número?** → Volumen, velocidad, variedad (+ veracidad, valor). La capacidad de procesamiento crece y cualquier cifra queda chica.
-  **Tipos de variables y ejemplo de cada una.** → Categórica, ordinal, discreta, continua.
- ¿Qué es KDD y qué busca la minería de datos?** → Descubrimiento de conocimiento en bases de datos; patrones, relaciones y anomalías sin conocimiento previo.
- Estadística descriptiva vs. inferencial.** → Datos disponibles vs. muestra → universo.
-  **¿Por qué es importante NumPy y qué caracteriza a ndarray?** → C/bajo nivel, memoria contigua, tamaño fijo, un solo tipo, más velocidad y menos memoria; base de Pandas y otras librerías; "parche" que une alto y bajo nivel.
- ¿Por qué una lista de Python es más lenta/pesada que un array?** → Es mutable y heterogénea; reserva memoria de más.
- ¿Qué es una Series y qué es un DataFrame? ¿Por qué no tienen flatten?** → §4.2.
- loc vs. iloc.** → Etiquetas vs. posiciones.
-  **Diferencia entre valor atípico e inconsistente y cómo se trata cada uno.** → §5.4.
-  **¿Qué es el Z-score y para qué sirve?** → Cuántos desvíos estándar se aleja un registro de la media; detecta atípicos.
- ¿Cómo se detectan atípicos?** → Boxplot, Z-score, IQR, ML (multivariado: Mahalanobis, MCD/MVE, LOF).
- Patrones de no respuesta: ¿cuáles son y cuál es el más grave? ¿por qué?** → Completamente aleatoria, aleatoria, no aleatoria; la no aleatoria por el problema circular.
- ¿Qué es un ponderador y cómo se calcula? ¿Qué es reponderar?** → Población/muestra; ajustarlo para que los respondentes representen a los no respondentes.
- Técnicas de imputación.** → Medias condicionadas, hot deck, modelos de ML ( también media/mediana, KNN, imputación múltiple).
- ¿Qué hace la transformación logarítmica con los atípicos? ¿Y el Z-score?** → La log les quita influencia; el Z-score exagera distancias.
-  **¿Qué tipo de medida es la mediana?** → Tendencia central y posición.
- ¿Por qué la mediana es más robusta que la media?** → No depende de los valores extremos.
- Si la media podada es mayor que la aritmética, ¿qué indica?** → Atípicos hacia abajo (asimetría negativa).
- Varianza poblacional vs. muestral.** → $/N$ vs. $/(N-1)$ (evita subestimar la dispersión).
- ¿Qué es el IQR y qué es el MAD?** → $Q3-Q1$; mediana de los desvíos absolutos respecto de la mediana.
- Covarianza vs. correlación de Pearson.** → La covarianza depende de la escala; la correlación la estandariza (-1 a 1). Ambas miden asociación lineal.
-  **¿Cómo se interpreta una matriz de correlación?** → Diagonal = 1; signo = sentido; cerca de 0 = sin asociación; negativo = inversa.
- ¿Qué medida usás para dos variables categóricas? ¿y numérica + categórica?** → V de Cramer; t de Student o eta.
- ¿Qué representan n y p? ¿Cuántos parámetros hay con p = 5?** → n filas, p columnas; $2 \cdot 5 + 5 \cdot 4 / 2 = 20$.
-  **Diferencia entre LGN y TCL. ¿Relación del TCL con el test de hipótesis?** → §2.

- 27. **¿Por qué Python se volvió el lenguaje de la IA?** → Legibilidad, NumPy, ecosistema (Pandas, TensorFlow, PyTorch), auge de la IA (*Attention Is All You Need*).
- 28. **¿Qué es ETL?** → Cargar, transformar y volver a guardar.
- 29. **¿Diferencia entre bases SQL y columnares?** → SQL por filas y consistencia; columnares por columnas y velocidad/disponibilidad.
- 30. **¿Qué son masking y swamping?** → Outliers que esconden a otros / observaciones normales clasificadas como outliers.
- 31. **¿Qué ventaja tiene Mahalanobis sobre la distancia euclídea?** → Pondera por la matriz de covarianzas y respeta la forma de la nube.
- 32. **¿Cuánto vale la traza de R? ¿Y qué representa la de Σ ?** → p; suma de varianzas (variabilidad total).
- 33. **¿Quiénes son Quetelet, Galton y Fisher y qué aportaron?** → §1.5.
- 34. **Diferencia entre M2M, IoT, WoT e IoE.** → §1.5.

11. ? Información de cursada

[? Volver al índice](#)

Aprobación y asistencia ?

- **16 clases** (sin feriados); **4** dedicadas a parciales. Asistencia mínima **75 % (3 faltas)** sobre 12 clases). **Hay que ponerse "presente" en el campus en cada clase.**
- **Regularizar: 4 o más en ambos** parciales. **Promocionar: 6 o más en ambos.**
- **Primer parcial:** teórico (2 de octubre). **Segundo parcial: trabajo práctico final** (entrega **virtual**; segunda mitad de la cursada; la defensa "se verá").
- **Integrador (11 de diciembre):** solo para quienes **no regularizaron**; **nota máxima 4**; **única** fecha para regularizar. También es fecha de **final** para quienes regularizaron (quienes promocionan no rinden final).
- El docente **tiende a adherir a los paros docentes** (única causa de cambios en el cronograma; la clase del 18/09 no se dictó).

Bibliografía ?

Texto	Uso
? Chan, Badano y Rey — <i>Análisis inteligente de datos</i> (UTN FRBA)	Obligatoria y de cabecera. Clave: capítulos 1 y 2 (~70–73 págs.). Ejemplos en R , pero "lo fundamental son los conceptos"
McKinney — <i>Python para análisis de datos</i>	Obligatoria. Cómo usar Python (McKinney creó Pandas)
Mitchell (clásico de machine learning)	Optativa (modelado)
Texto de regresión lineal (docente de Exactas UBA)	Optativa (modelado)
Texto de Hernández (U. de La Rioja)	Optativa: perspectiva estadística tradicional

- Apuntes y ejercicios en el campus: "**Materiales y exámenes unificados**", carpeta *Apunte Fernández, Funcionamiento*.
- **Ejercicios:** cortos (~media hora por semana); sirven para parciales y TP. Clase 2: **levantar una base de microdatos**, la **EPH** (se usará en el TP).

TP final ?

- Se trabaja con la **EPH** y **ponderadores** (hay varios; saber cuándo usar cada uno).
- Cualquier lenguaje/entorno: se evalúa **lo que obtienen con el código** y **aplicar bien los conceptos**.
- ? Aplicar técnicas de variables cuantitativas a categóricas → recuperatorio.
- Después del primer parcial (sin IA) en el segundo/TP **sí pueden usar IA**.

12. ¶ Anexo: Álgebra lineal y Análisis de Componentes Principales (Cap. 3 del libro)

[¶ Volver al índice](#)

¶ El docente dijo que PCA y correspondencias NO entran en la materia. Se conserva completo por si querés profundizar o para etapas posteriores.

"La vida es el arte de obtener conclusiones suficientes a partir de premisas insuficientes." — Samuel Butler

12.1 Nociones previas de álgebra lineal

Para entender PCA se interpretan las variables como vectores en un espacio n -dimensional ($\mathbb{R}^n$).

Vectores y operaciones: $v = (v_1, \dots, v_n)$ es un segmento orientado desde el origen. **Suma:** $v + w = (v_1 + w_1, \dots, v_n + w_n)$. **Producto por escalar:** $\alpha v = (\alpha v_1, \dots, \alpha v_n)$.

Combinación lineal: u es combinación lineal de v y w si existen α, β tales que $u = \alpha v + \beta w$. Las combinaciones de un vector forman una **recta**; las de dos de distinta dirección, un **plano**. Estadísticamente permite **crear nuevas variables** sin añadir dimensionalidad.

Ejemplo (natación): 14 nadadores, 4 tramos ($v_1 \dots v_4$). $w_1 = 1/2 v_1 + 1/2 v_2$ (promedio de los dos primeros tramos), $w_2 = 1/2 v_3 + 1/2 v_4$ (promedio de los dos últimos), $w_3 = w_1 - w_2$ (diferencia). Todas pertenecen al espacio generado por las 4 originales.

Dependencia e independencia lineal:

- **Linealmente dependientes (l.d.):** el vector nulo se expresa como combinación lineal con algún coeficiente no nulo (al menos un vector es combinación del resto). **Variable redundante** (ej. altura en cm y en metros); dos vectores l.d. están sobre la misma recta.
- **Linealmente independientes (l.i.):** ningún vector es combinación de los otros; cada variable aporta **información única**.

Espacio generado y bases:

- $gen(T)$: todos los vectores que se forman combinando los de T (un vector genera una recta; dos independientes, un plano).
- **Base:** conjunto de vectores l.i. que genera todo el espacio; su cantidad es la **dimensión**. Base canónica de $\mathbb{R}^2$: $e_1 = (1,0)$, $e_2 = (0,1)$.

12.2 Transformaciones lineales

Se transforma el espacio original en otro (incluso de distinta dimensión). Las más frecuentes: **proyecciones**, **rotaciones** y **reflexiones (simetrías)**.

Proyecciones (Ej. 3.2): reducen dimensión "aplastando" los datos sobre un subespacio (ej. 3D a 2D). El objetivo condiciona la proyección:

- **PCA:** maximiza la **varianza** (la mayor "sombra" o dispersión).
- **Análisis discriminante:** **discrimina mejor las clases**, aunque sacrifique varianza.
- La proyección óptima **no es única**.

Simetrías (Ej. 3.3): reflexión respecto al eje de abscisas, $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$:

$$T(x, y) = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x \\ -y \end{pmatrix}$$

Involución ($T \circ T = \text{id}$): con $M_E(T)$ la matriz en la base canónica,

$$M_E(T)^2 = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I$$

Aplicar la transformación dos veces devuelve cada punto a su posición original.

13. Glosario

[🔗 Volver al índice](#)

Término	Idea clave
KDD	Descubrimiento de conocimiento en bases de datos; el Data Mining es su fase analítica
Hipotético-deductivo vs. inductivo	Contrastar una hipótesis vs. generalizar desde los datos
Big Data	Volumen, velocidad, variedad (+ veracidad, valor); concepto, no cifra
M2M / IoT / WoT / IoE	Máquinas entre sí / objetos en internet / objetos en la Web / personas-procesos-datos-cosas
Robusto	Poco afectado por outliers (mediana, MAD, IQR, MCD, MVE)
Atípico / inconsistente	Raro pero posible / imposible o incoherente
Z-score	$(x - \text{media}) / \text{desvío}$; media 0, varianza 1
Ponderador	Población / muestra; casos que representa cada registro
Σ vs. R	Covarianzas (dependen de unidades) vs. correlaciones (-1 a 1)
$\text{tr}(\Sigma) / \text{tr}(R)$	Suma de varianzas / igual a p
Masking / Swamping	Outliers que esconden a otros / normales que parecen outliers
Mahalanobis	Distancia que pondera por Σ^{-1}
I.d. / I.i.	Variables redundantes / información única
Base y dimensión	Conjunto I.i. que genera el espacio; su tamaño es la dimensión
PCA vs. discriminante	Maximiza varianza vs. maximiza separación de clases
Involución	$T \circ T = \text{id}$, es decir $M^2 = I$

Fin de la guía unificada · ¡Éxitos en el parcial del viernes 2 de octubre! 📖